

Nettoyage et manipulation des données avec R

Introduction au tidyverse

Amal Tawfik

2026-01-15

Plan

- Introduction au `tidyverse`
- Structure des données et principes *tidy*
- Nettoyer le tableau de données (`janitor`)
- Le *pipe* : enchaîner les opérations
- Manipulation des données avec `dplyr` : `filter()`, `select()`, `arrange()`, `mutate()`, `summarise()`, `group_by()`
- Résumés globaux vs par groupe
- Recoder des variables (`ifelse()`, `case_when()`) et interfaces graphiques

Objectifs

- Transformer un fichier brut en un `data.frame` (ou `tibble`) propre et prêt pour l'analyse.

Pour y parvenir :

- Identifier et corriger les problèmes courants dans les données brutes
- Utiliser les outils du `tidyverse` pour nettoyer les données
- Structurer vos données selon les principes *tidy*
- Préparer vos données pour l'analyse statistique

Pourquoi nettoyer les données ?

80% du temps est consacré à la préparation et au nettoyage des données, et seulement 20% à l'analyse.

Ce qu'on rencontre dans les données brutes :

- valeurs manquantes (`NA`, cases vides)

- codages incohérents (F, f, 1, 2, etc.)
- erreurs de saisie (99999 comme revenu)
- doublons (individu présent plusieurs fois)
- classes erronées (âge importé comme texte)
- colonnes inutiles ou mal nommées

Qu'est-ce que le *tidyverse* ?

Le **tidyverse** est un ensemble cohérent de packages R dédiés à la *science des données*, conçu pour être :

- lisible
- expressif
- reproductible
- intuitif

Il repose sur une philosophie commune, une syntaxe uniforme et la structure *tidy* des données.

- Installation en une fois : `install.packages("tidyverse")`
- Charger le tidyverse : `library(tidyverse)`

Les packages principaux du *tidyverse*

Le **tidyverse** fournit des outils pour chaque étape du *data workflow* :

| Étape | Packages & utilités |
|--------------------|--|
| Importer | <code>readr</code> (CSV), <code>readxl</code> (Excel), <code>haven</code> (SPSS/Stata/SAS) |
| Manipuler | <code>dplyr</code> : filtrer, trier, sélectionner, créer des variables |
| Restructurer | <code>tidyr</code> : pivoter (long wide), séparer, combiner |
| Visualiser | <code>ggplot2</code> : graphiques élégants et cohérents |
| Gérer les textes | <code>stringr</code> : chaînes de caractères |
| Gérer les facteurs | <code>forcats</code> : niveaux, réordonnements |
| Gérer les dates | <code>lubridate</code> : dates, heures, durées |
| Tibble moderne | <code>tibble</code> : version améliorée d'un <code>data.frame</code> |

Tous ces packages partagent une syntaxe cohérente et fonctionnent parfaitement ensemble.

Structure d'un tableau de données : variables, valeurs et observations

- Une **variable** représente une caractéristique mesurée (quantité, qualité, propriété).
- Une **valeur** est le résultat obtenu pour une variable lors d'une mesure.
- Une **observation** regroupe l'ensemble des valeurs mesurées dans les mêmes conditions (cas ou individu statistique).
- Un **tableau de données rectangulaire** associe chaque valeur à une variable (colonne) et à une observation (ligne).

Dans R, ce type de tableau est représenté par un `data.frame` et sa version modernisée est le `tibble`.

Données *tidy*

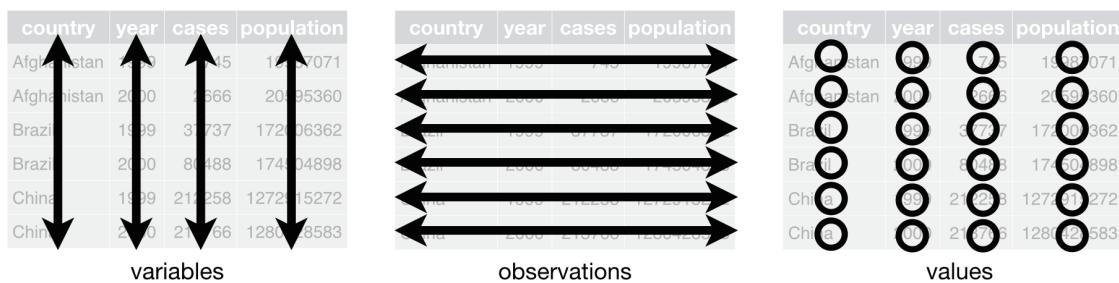
Tous les tableaux de données rectangulaires ne sont pas également faciles à utiliser pour l'analyse.

Plusieurs tableaux peuvent représenter les mêmes données, mais seule une structure *tidy* est pleinement exploitable dans le `tidyverse`.

Les données sont dites *tidy* (rangées) lorsque trois règles interdépendantes sont respectées :

- chaque variable correspond à une colonne
- chaque observation correspond à une ligne
- chaque valeur occupe une cellule et chaque cellule contient une seule valeur (pas de valeurs empilées du type “foot, basket, tennis”, ni de valeurs composites du type “23 kg”)

Visualisation de la structure *tidy*



The diagram illustrates the tidy data structure through three representations of the same dataset:

- variables:** A wide table where each column represents a variable (country, year, cases, population). Arrows point from the column headers to the columns.
- observations:** A long table where each row represents an observation. Arrows point from the column headers to the columns.
- values:** A circular representation where each cell contains a single value, showing the mapping from variables to observations.

Below each table is a label indicating the structure: "variables", "observations", and "values".

| country | year | cases | population |
|-------------|------|--------|------------|
| Afghanistan | 1999 | 145 | 1907071 |
| Afghanistan | 2000 | 6366 | 2059360 |
| Brazil | 1999 | 37737 | 17206362 |
| Brazil | 2000 | 80488 | 17404898 |
| China | 1999 | 212258 | 1272015272 |
| China | 2000 | 21366 | 128048583 |

| country | year | cases | population |
|-------------|------|--------|------------|
| Afghanistan | 1999 | 145 | 1907071 |
| Afghanistan | 2000 | 6366 | 2059360 |
| Brazil | 1999 | 37737 | 17206362 |
| Brazil | 2000 | 80488 | 17404898 |
| China | 1999 | 212258 | 1272015272 |
| China | 2000 | 21366 | 128048583 |

| country | year | cases | population |
|-------------|------|--------|------------|
| Afghanistan | 1999 | 145 | 1907071 |
| Afghanistan | 2000 | 6366 | 2059360 |
| Brazil | 1999 | 37737 | 17206362 |
| Brazil | 2000 | 80488 | 17404898 |
| China | 1999 | 212258 | 1272015272 |
| China | 2000 | 21366 | 128048583 |

Source : <https://r4ds.hadley.nz/data-tidy.html#fig-tidy-structure>

En pratique, que change la structure *tidy* ?

Lorsque ces règles sont respectées :

- chaque unité d'observation est clairement identifiée
- des unités d'observation différentes sont stockées dans des tables distinctes

Conséquence : on évite de mélanger individus, événements et mesures dans une même table.

Les données *tidy* respectent une structure standardisée, conçue pour faciliter la manipulation, la visualisation et l'analyse avec les outils du **tidyverse**.

Les *tibbles*

Dans le **tidyverse**, les données sont manipulées sous forme de **tibble**, une version moderne et améliorée de **data.frame** de R.

Les **tibbles** sont :

- fournis par le package **tibble** (au cœur du **tidyverse**)
- acceptés par la plupart des fonctions du **tidyverse**
- retournés par défaut par **dplyr**, **tidyr**, **ggplot2**, etc.

Un **tibble** est un **data.frame** plus strict, plus lisible et plus sûr.

Pourquoi utiliser des *tibbles* ?

Contrairement aux **data.frames** classiques, les **tibbles** :

- n'ont pas de noms de lignes (**rownames**)
- autorisent des noms de colonnes non standards (espaces, caractères spéciaux, nombres...) entourés avec des backticks (`)
- s'affichent intelligemment (aperçu des lignes, dimensions, types de variables)
- pas de *partial matching* sur les noms de colonnes (si une table d contient une colonne **qualif**, d\$**qual** ne retournera pas cette colonne)
- avertissent lorsqu'une colonne n'existe pas

Ils font moins de choses automatiques mais signalent plus tôt les erreurs

Compatibilité de tibble et data.frame

Un **tibble** reste totalement compatible avec un **data.frame** :

- la plupart des fonctions du tidyverse acceptent un **data.frame** en entrée
- elles retournent généralement un **tibble**

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr     1.1.4     v readr     2.1.6
v forcats   1.0.1     v stringr   1.6.0
v ggplot2   4.0.1     v tibble    3.3.0
v lubridate 1.9.4     v tidyr    1.3.2
v purrr    1.2.0

-- Conflicts -----
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become non-conflicting
```

```
head(mtcars) # Affiche les 6 premières lignes (n = 6 par défaut)
```

| | mpg | cyl | disp | hp | drat | wt | qsec | vs | am | gear | carb |
|-------------------|------|-----|------|-----|------|-------|-------|----|----|------|------|
| Mazda RX4 | 21.0 | 6 | 160 | 110 | 3.90 | 2.620 | 16.46 | 0 | 1 | 4 | 4 |
| Mazda RX4 Wag | 21.0 | 6 | 160 | 110 | 3.90 | 2.875 | 17.02 | 0 | 1 | 4 | 4 |
| Datsun 710 | 22.8 | 4 | 108 | 93 | 3.85 | 2.320 | 18.61 | 1 | 1 | 4 | 1 |
| Hornet 4 Drive | 21.4 | 6 | 258 | 110 | 3.08 | 3.215 | 19.44 | 1 | 0 | 3 | 1 |
| Hornet Sportabout | 18.7 | 8 | 360 | 175 | 3.15 | 3.440 | 17.02 | 0 | 0 | 3 | 2 |
| Valiant | 18.1 | 6 | 225 | 105 | 2.76 | 3.460 | 20.22 | 1 | 0 | 3 | 1 |

Conversion de data.frame en tibble

as_tibble() convertit un **data.frame** en **tibble** :

- les variables et leurs types sont conservés
- les **rownames** sont supprimés par défaut

```
as_tibble(mtcars)
```

```
# A tibble: 32 x 11
  mpg cyl disp  hp drat    wt  qsec    vs    am gear carb
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 21     6   160   110  3.9   2.62  16.5    0     1     4     4
2 21     6   160   110  3.9   2.88  17.0    0     1     4     4
3 22.8   4   108   93   3.85  2.32  18.6    1     1     4     1
4 21.4   6   258   110  3.08  3.22  19.4    1     0     3     1
5 18.7   8   360   175  3.15  3.44  17.0    0     0     3     2
6 18.1   6   225   105  2.76  3.46  20.2    1     0     3     1
7 14.3   8   360   245  3.21  3.57  15.8    0     0     3     4
8 24.4   4   147.   62   3.69  3.19   20      1     0     4     2
9 22.8   4   141.   95   3.92  3.15  22.9    1     0     4     2
10 19.2   6   168.   123  3.92  3.44  18.3    1     0     4     4
# i 22 more rows
```

Convertir les noms de lignes en variables

Il est possible de transformer les `rownames` en colonne explicite en utilisant l'argument `rownames` :

```
as_tibble(mtcars, rownames = "car_names")
```

```
# A tibble: 32 x 12
  car_names     mpg cyl disp  hp drat    wt  qsec    vs    am gear carb
  <chr>       <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 Mazda RX4    21     6   160   110  3.9   2.62  16.5    0     1     4     4
2 Mazda RX4 ~  21     6   160   110  3.9   2.88  17.0    0     1     4     4
3 Datsun 710   22.8   4   108   93   3.85  2.32  18.6    1     1     4     1
4 Hornet 4 D~  21.4   6   258   110  3.08  3.22  19.4    1     0     3     1
5 Hornet Spo~  18.7   8   360   175  3.15  3.44  17.0    0     0     3     2
6 Valiant      18.1   6   225   105  2.76  3.46  20.2    1     0     3     1
7 Duster 360   14.3   8   360   245  3.21  3.57  15.8    0     0     3     4
8 Merc 240D    24.4   4   147.   62   3.69  3.19   20      1     0     4     2
9 Merc 230     22.8   4   141.   95   3.92  3.15  22.9    1     0     4     2
10 Merc 280    19.2   6   168.   123  3.92  3.44  18.3    1    0     4     4
# i 22 more rows
```

Nettoyer les noms des variables

Le package `janitor` fournit des outils simples pour nettoyer et standardiser les données.

Souvent, les données importées contiennent des colonnes avec :

- des espaces
- des caractères spéciaux
- des majuscules mélangées
- des noms peu lisibles

La fonction `clean_names()` nettoie les noms de colonnes pour qu'ils soient propres, cohérents et faciles à manipuler.

Que fait `clean_names()` ?

Par défaut, la fonction `clean_names()` du package `janitor` applique la convention de nommage *snake case* qui est la convention recommandée dans le `tidyverse`.

Elle transforme les noms de colonnes pour :

- être en minuscules
- remplacer les espaces et caractères spéciaux par des *underscores* (_)
- éviter les noms invalides ou ambigus
- produire des noms faciles à taper et cohérents

Exemple

```
library(janitor)
```

Attachement du package : 'janitor'

Les objets suivants sont masqués depuis 'package:stats':

```
chisq.test, fisher.test

d <- tibble(
  "Nom Col 1" = 1:3,
  "Âge (ans)" = c(24, 30, 29),
  "Score (%)" = c(80, 90, 85)
)
d
```

```
# A tibble: 3 x 3
`Nom Col 1` `Âge (ans)` `Score (%)`
<int>      <dbl>      <dbl>
1         1        24        80
2         2        30        90
3         3        29        85
```

```
clean_names(d)
```

```
# A tibble: 3 x 3
nom_col_1 age_ans score_percent
<int>     <dbl>      <dbl>
1         1        24        80
2         2        30        90
3         3        29        85
```

Autres fonctions utiles de nettoyage

Plusieurs autres fonctions du package [janitor](#) :

- [remove_empty\(\)](#) supprime les lignes ou colonnes entièrement composées de NA.
- [get_dups\(\)](#) identifie les doublons sur une ou plusieurs variables.

Exemple

```
d <- tibble(
  id    = c(1, 2, 2, NA),
  nom   = c("Alice", "Bob", "Bob", NA),
  score = c(15, 10, 15, NA),
  vide  = c(NA, NA, NA, NA))
d
```

```
# A tibble: 4 x 4
  id nom   score vide
<dbl> <chr> <dbl> <lgl>
1   1 Alice   15  NA
2   2 Bob     10  NA
3   2 Bob     15  NA
4   NA <NA>    NA  NA
```

Exemples

```
remove_empty(d)
```

```
value for "which" not specified, defaulting to c("rows", "cols")
```

```
# A tibble: 3 x 3
  id nom   score
  <dbl> <chr> <dbl>
1     1 Alice    15
2     2 Bob      10
3     2 Bob      15
```

```
remove_empty(d, which = "cols")
```

```
# A tibble: 4 x 3
  id nom   score
  <dbl> <chr> <dbl>
1     1 Alice    15
2     2 Bob      10
3     2 Bob      15
4     NA <NA>     NA
```

```
get_dupes(d, score)
```

```
# A tibble: 2 x 5
  score dupe_count   id nom   vide
  <dbl>       <int> <dbl> <chr> <lgl>
1     15          2     1 Alice NA
2     15          2     2 Bob   NA
```

```
get_dupes(d, id, nom)
```

```
# A tibble: 2 x 5
  id nom   dupe_count score vide
  <dbl> <chr>       <int> <dbl> <lgl>
1     2 Bob           2     10 NA
2     2 Bob           2     15 NA
```

Le *pipe* : enchaîner les opérations

Le *pipe* (`|>` natif R ou `%>%` du package `magrittr`) permet d'enchaîner plusieurs opérations dans l'ordre où on les lit.

Principe : Ce qui se trouve **à gauche** du pipe est envoyé comme premier argument à la fonction **à droite**.

```
data |> fonction1() |> fonction2() |> fonction3()

data |>
  fonction1() |>
  fonction2() |>
  fonction3()
```

“Prends cet objet → puis applique cette transformation → puis cette autre → etc.”

Pourquoi utiliser le *pipe* ?

Exemple

```
d <- tibble(
  id_etud = c("E001", "E002", "E003", "E004"),
  genre = factor(c("F", "H", "F", "H")),
  age = c(17, 20, 23, 19),
  filiere = factor(c("Soins infirmiers",
                    "Physiothérapie",
                    "Soins infirmiers",
                    "Ergothérapie")),
  abs_just = c(2, 4, 1, 3),
  abs_non_just = c(0, 1, 2, 0),
  revenu = c(6200, NA, NA, 4800)
)
d
```



```
# A tibble: 4 x 7
  id_etud genre   age filiere      abs_just abs_non_just revenu
  <chr>    <fct> <dbl> <fct>        <dbl>        <dbl>     <dbl>
1 E001      F     17 Soins infirmiers     2            0     6200
2 E002      H     20 Physiothérapie      4            1       NA
3 E003      F     23 Soins infirmiers     1            2       NA
4 E004      H     19 Ergothérapie        3            0     4800
```

Sans *pipe*, deux problèmes courants

1. Fonctions imbriquées (difficile à lire, ordre inversé) :

```
d1 <- select(  
  mutate(  
    filter(d, age >= 18),  
    abs_total = abs_just + abs_non_just  
  ),  
  id_etud, genre, filiere, abs_total  
)  
d1
```

```
# A tibble: 3 x 4  
  id_etud genre filiere      abs_total  
  <chr>   <fct> <fct>       <dbl>  
1 E002     H     Physiothérapie     5  
2 E003     F     Soins infirmiers    3  
3 E004     H     Ergothérapie      3
```

2. Objets intermédiaires (répétitif, risque d'erreur) :

```
d1 <- filter(d, age >= 18)  
d1 <- mutate(d1, abs_total = abs_just + abs_non_just)  
d1 <- select(d1, id_etud, genre, filiere, abs_total)  
d1
```

```
# A tibble: 3 x 4  
  id_etud genre filiere      abs_total  
  <chr>   <fct> <fct>       <dbl>  
1 E002     H     Physiothérapie     5  
2 E003     F     Soins infirmiers    3  
3 E004     H     Ergothérapie      3
```

Le *pipe* : lire le code comme une phrase

Avec *pipe*, lisible de gauche à droite (et de haut en bas) :

```
d1 <- d |>
  filter(age >= 18) |>
  mutate(abs_total = abs_just + abs_non_just) |>
  select(id_etud, genre, filiere, abs_total)
d1
```

```
# A tibble: 3 x 4
  id_etud genre filiere      abs_total
  <chr>    <fct> <fct>        <dbl>
1 E002     H     Physiothérapie     5
2 E003     F     Soins infirmiers   3
3 E004     H     Ergothérapie      3
```

On lit le code comme une phrase

“Crée `d1` en prenant `d`, en filtrant les personnes de 18 ans ou plus, en ajoutant une variable `abs_total` qui additionne les absences justifiées et non justifiées, puis en sélectionnant uniquement les variables `id_etud`, `genre`, `filiere` et `abs_total`.”

Les avantages du *pipe*

Enchaîner les opérations avec `|>` (appelé *pipeline*) permet :

- Lisibilité : le code se lit comme une phrase, dans l'ordre naturel
- Modularité : facile d'ajouter ou retirer une étape
- Débogage : on peut tester étape par étape
- Reproductibilité : chaque transformation est explicite

À retenir :

- On sauvegarde le résultat final dans un objet : `resultat <- donnees |> ...`
- Le *pipe* n'est pas qu'un outil syntaxique, c'est une façon de penser la transformation des données

Manipuler les données avec dplyr

dplyr est le package du tidyverse dédié à la manipulation de données. Il propose une syntaxe claire et cohérente, sous forme de verbes, pour transformer une ou plusieurs tables.

Les principaux verbes de manipulation :

| Action sur les données | Verbe de dplyr |
|---|---------------------------------------|
| Sélectionner des lignes (observations) | <code>filter()</code> |
| Sélectionner ou réordonner des colonnes (variables) | <code>select()</code> |
| Trier les observations | <code>arrange()</code> |
| Créer ou transformer des variables | <code>mutate()</code> |
| Résumer les données (par groupe) | <code>summarise() + group_by()</code> |

Sélectionner des lignes (observations) — filter()

La fonction `filter()` permet de conserver uniquement les lignes qui satisfont une ou plusieurs conditions.

- Elle agit sur les observations (lignes), pas sur les variables (colonnes).

Principe

```
data |> filter(condition)
```

- la condition doit être TRUE pour que la ligne soit conservée
- plusieurs conditions peuvent être combinées (&, |)

Exemple : conserver les personnes âgées de 18 ans ou plus

```
d |> filter(age >= 18)
```

Écrire des conditions logiques

Pour sélectionner des observations (créer des sous-ensembles) ou recoder des variables, on écrit des **conditions logiques**.

Une condition est une expression logique dont le résultat est :

- TRUE = la ligne est conservée
- FALSE = la ligne est exclue

Les conditions reposent sur :

- des opérateurs de comparaison
- des opérateurs logiques

`filter()` conserve uniquement les lignes pour lesquelles la condition est vraie.

Opérateurs logiques et de comparaison

Opérateurs de comparaison

| Opérateur | Signification |
|--------------------|-------------------------|
| <code>==</code> | égal à |
| <code>!=</code> | différent de |
| <code>></code> | strictement supérieur à |
| <code><</code> | strictement inférieur à |
| <code>>=</code> | supérieur ou égal à |
| <code><=</code> | inférieur ou égal à |

Opérateurs logiques

| Opérateur | Signification |
|--------------------|------------------|
| <code>&</code> | ET logique |
| <code> </code> | OU logique |
| <code>!</code> | négation logique |

Exemples de conditions logiques avec `filter()`

```
d |> filter(age < 18) # comparaison
```

```
# A tibble: 1 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>       <dbl>     <dbl>
1 E001     F        17 Soins infirmiers      2          0     6200
```

```
d |> filter(genre == "F") # égalité
```

```
# A tibble: 2 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>       <dbl>     <dbl>
1 E001    F        17  Soins infirmiers     2          0    6200
2 E003    F        23  Soins infirmiers     1          2     NA
```

```
d |> filter(abs_just >= 4 & genre == "H") # ET
```

```
# A tibble: 1 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>       <dbl>     <dbl>
1 E002    H        20  Physiothérapie    4          1     NA
```

```
d |> filter(filiere == "Physiothérapie" | filiere == "Ergothérapie") # OU
```

```
# A tibble: 2 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>       <dbl>     <dbl>
1 E002    H        20  Physiothérapie    4          1     NA
2 E004    H        19  Ergothérapie      3          0    4800
```

```
d |> filter(!is.na(revenu)) # valeurs non manquantes
```

```
# A tibble: 2 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>       <dbl>     <dbl>
1 E001    F        17  Soins infirmiers     2          0    6200
2 E004    H        19  Ergothérapie      3          0    4800
```

Sélectionner des colonnes (variables) — `select()`

La fonction `select()` permet de choisir, réordonner ou supprimer des variables (colonnes).

- Elle agit sur les variables (colonnes), pas sur les observations (lignes).

Principe

```
data |> select(col1, col2, ...)
```

- on indique les variables à conserver

- l'ordre d'écriture = ordre final des variables

Exemple : conserver uniquement les variables `id_etud` et `genre`.

```
d |> select(id_etud, genre)
```

Sélectionner une plage de variables — `select()`

Sélectionner un ensemble de variables consécutives en utilisant ::

```
d |> select(genre:filiere)
```

```
# A tibble: 4 x 3
  genre    age filiere
  <fct> <dbl> <fct>
1 F        17 Soins infirmiers
2 H        20 Physiothérapie
3 F        23 Soins infirmiers
4 H        19 Ergothérapie
```

`genre:filiere` sélectionne toutes les variables de `genre` à `filiere` incluses (selon leur ordre dans le tableau).

Quand l'utiliser ?

- Lorsque les variables se suivent dans le tableau
- Pour éviter d'écrire une longue liste de noms de variables

La sélection par plage dépend de l'ordre des variables dans le tableau.

Réordonner les variables (colonnes) — `select()`

`select()` permet aussi de changer l'ordre des variables dans le tableau de données.

Exemple : placer `revenu` en première colonne, puis conserver toutes les autres avec `everything()`.

```
d |> select(revenu, everything())
```

```
# A tibble: 4 x 7
  revenu id_etud genre    age filiere      abs_just abs_non_just
  <dbl>   <chr>  <fct> <dbl> <fct>        <dbl>       <dbl>
1     6200 E001    F      17 Soins infirmiers     2          0
2      NA E002    H      20 Physiothérapie     4          1
3      NA E003    F      23 Soins infirmiers     1          2
4     4800 E004    H      19 Ergothérapie      3          0
```

Utilités :

- Mettre les variables clés au début du tableau de données
- Faciliter la lecture et la compréhension des données avant une analyse ou une exportation

Sélecteurs de colonnes (*helpers*)

`select()` propose des **sélecteurs** (*helpers*) pour choisir plusieurs variables sans écrire leurs noms un par un. Ces fonctions sont fournies par le package `tidyselect` dont la liste est [ici](#).

Exemples de sélecteurs : `starts_with()`, `ends_with()`, `contains()`

```
d |> select(starts_with("abs"))    # commence par "abs"
```

```
# A tibble: 4 x 2
  abs_just abs_non_just
  <dbl>       <dbl>
1     2          0
2     4          1
3     1          2
4     3          0
```

```
d |> select(ends_with("_just"))    # se termine par "_just"
```

```
# A tibble: 4 x 2
  abs_just abs_non_just
  <dbl>       <dbl>
1     2          0
2     4          1
3     1          2
4     3          0
```

```
d |> select(contains("age"))      # contient "age"
```

```
# A tibble: 4 x 1
  age
  <dbl>
1 17
2 20
3 23
4 19
```

Supprimer ou renommer des variables

Supprimer une variable avec - :

```
d |> select(-abs_non_just)      # supprimer "abs_non_just"
```

```
# A tibble: 4 x 6
  id_etud genre    age filiere      abs_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>   <dbl>
1 E001    F       17  Soins infirmiers     2     6200
2 E002    H       20  Physiothérapie      4     NA
3 E003    F       23  Soins infirmiers     1     NA
4 E004    H       19  Ergothérapie       3     4800
```

Renommer des variables :

```
d |>
  select(identifiant = id_etud,
         sexe = genre,
         revenu)
```

```
# A tibble: 4 x 3
  identifiant sexe   revenu
  <chr>       <fct> <dbl>
1 E001        F     6200
2 E002        H     NA
3 E003        F     NA
4 E004        H     4800
```

Trier les observations — `arrange()`

La fonction `arrange()` permet de trier les lignes (observations) d'un tableau selon une ou plusieurs variables.

Elle change uniquement l'ordre des observations, sans modifier les valeurs.

Principe

```
data |> arrange(variable)
```

- le tri est croissant par défaut
- les valeurs manquantes (NA) sont placées à la fin

Exemple : trier les observations par âge croissant

```
d |> arrange(age)
```

Trier selon plusieurs variables — `arrange()`

Il est possible de trier selon plusieurs variables, dans l'ordre indiqué.

Exemple : trier d'abord par `filiere`, puis par `age` à l'intérieur de chaque `filiere`.

```
d |> arrange(filiere, age)
```

```
# A tibble: 4 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>        <dbl>     <dbl>
1 E004    H       19 Ergothérapie     3           0     4800
2 E002    H       20 Physiothérapie   4           1       NA
3 E001    F       17 Soins infirmiers 2           0     6200
4 E003    F       23 Soins infirmiers 1           2       NA
```

Pour trier en ordre décroissant, on utilise `desc()` :

```
d |> arrange(desc(revenu))
```

```
# A tibble: 4 x 7
  id_etud genre    age filiere      abs_just abs_non_just revenu
  <chr>   <fct> <dbl> <fct>        <dbl>        <dbl>     <dbl>
1 E001    F       17 Soins infirmiers 2           0     6200
2 E004    H       19 Ergothérapie     3           0     4800
3 E002    H       20 Physiothérapie   4           1       NA
4 E003    F       23 Soins infirmiers 1           2       NA
```

Créer ou transformer des variables — `mutate()`

La fonction `mutate()` permet de :

- créer de nouvelles variables
- transformer/recoder des variables existantes

Elle ne modifie pas le nombre d'observations.

Principe

```
data |> mutate(nouvelle_variable = expression)
```

- la nouvelle variable est ajoutée au tableau

Exemple : créer une variable `abs_total` (total des absences)

```
d |> mutate(abs_total = abs_just + abs_non_just)
```

Exemples avec `mutate()`

```
d <- d |>
  mutate(
    age2 = age^2,                                     # transformation numérique (au carré)
    majeur = age >= 18,                                # indicateur logique TRUE / FALSE
    age_plus_1 = age + 1,                               # création d'une nouvelle variable
    abs_total = abs_just + abs_non_just,                # somme de deux variables
    abs_dicho = as.integer(abs_total > 3),            # indicateur binaire (1 si > 3 absences, 0 sinon)
    id_etud = as.factor(id_etud)                      # transformation en facteur
  )
```

```
d
```

```
# A tibble: 4 x 12
  id_etud genre   age filiere      abs_just abs_non_just revenu  age2 majeur age_plus_1
  <fct>   <fct> <dbl> <fct>        <dbl>       <dbl> <dbl> <dbl> <lgl>    <dbl>
1 E001     F      17 Soins infirmiers     2          0    6200  289 FALSE      18
2 E002     H      20 Physiothérapie      4          1     NA    400  TRUE       21
3 E003     F      23 Soins infirmiers     1          2     NA    529  TRUE       24
4 E004     H      19 Ergothérapie        3          0    4800  361  TRUE       20
```

Dans `mutate()`, les variables sont créées de haut en bas : une variable nouvellement créée peut être réutilisée immédiatement.

Résumer les données — `summarise()`

La fonction `summarise()` permet de calculer des statistiques sur une ou plusieurs variables d'un tableau de données.

- Elle retourne un nouveau tableau contenant uniquement les résumés spécifiés.

Principe

```
data |>
  summarise(
    nom_stat1 = expression1,
    nom_stat2 = expression2
  )
```

- Chaque `expression` calcule une statistique
- Le résultat est un *tibble* réduit contenant les nouvelles variables

Exemple d'utilisation de `summarise()`

`n()` retourne le nombre d'observations (lignes)

Exemple : un *tibble* avec 3 variables résumé.

```
d |>
  summarise(
    n = n(),                                # nombre total d'observations
    age_moyen = mean(age, na.rm = TRUE),      # moyenne (ignore les NA)
    revenu_max = max(revenu, na.rm = TRUE)    # maximum (ignore les NA)
  )

# A tibble: 1 x 3
  n   age_moyen  revenu_max
  <int>     <dbl>      <dbl>
1     4        19.8       6200
```

`summarise()` agrège les données : elle produit un ou des résumés statistiques.

Résumer les données par groupe

`group_by()` définit des groupes d'observations à partir d'une ou plusieurs variables et `summarise()` calcule des statistiques pour chaque groupe.

Principe

```
data |>
  group_by(variable_groupe) |>      # crée des groupes
  summarise(nom_stat = expression) # calcule une statistique par groupe
```

Exemple : un *tibble* avec 1 ligne par filière contenant les résumés.

```
d |>
  group_by(filiere) |>          # crée un groupe par filière
  summarise(
    n = n(),                  # nombre d'observations par filière
    age_moyen = mean(age, na.rm = TRUE) # moyenne d'âge par filière (ignore les NA)
  )
```



```
# A tibble: 3 x 3
  filiere      n  age_moyen
  <fct>     <int>    <dbl>
1 Ergothérapie 1      19
2 Physiothérapie 1      20
3 Soins infirmiers 2      20
```

summarise() : global vs par groupe

- Sans `group_by()`, `summarise()` calcule une statistique globale : le résultat contient une seule ligne et une variable par statistique demandée.
- Avec `group_by()`, `summarise()` calcule une statistique par groupe : une ligne est produite pour chaque groupe et une variable par statistique demandée.
- Les fonctions comme `mean()`, `sum()`, `min()`, `max()`, `sd()`, `median()`, `n()` sont fréquemment utilisées dans `summarise()`.

Recoder une variable — `ifelse()`

La fonction `ifelse()` permet de créer ou recoder une variable en appliquant une condition simple.

Elle fonctionne comme un “si ... alors ... sinon ...”.

Principe

```
ifelse(condition, valeur_si_vrai, valeur_si_faux)
```

Exemples : créer une variable `majeur` (oui/non) et dichotomiser le revenu

```
d |>
  mutate(
    majeur = ifelse(age >= 18, "oui", "non"),
    rev_haut = ifelse(revenu > 5000, 1, 0)
  )
```

```
# A tibble: 4 x 13
  id_etud genre   age filiere      abs_just abs_non_just revenu  age2 majeur age_plus_1
  <fct>   <fct> <dbl> <fct>       <dbl>        <dbl>   <dbl> <dbl> <chr>    <dbl>
1 E001     F      17 Soins infirmiers     2          0    6200  289 non      18
2 E002     H      20 Physiothérapie      4          1      NA  400 oui      21
3 E003     F      23 Soins infirmiers     1          2      NA  529 oui      24
4 E004     H      19 Ergothérapie        3          0    4800  361 oui      20
```

Recoder avec `ifelse()` — bonnes pratiques

- `ifelse()` est adapté aux recodages binaires (2 catégories).
- La condition de `ifelse()` peut utiliser plusieurs variables (ex. `ifelse(age >= 18 & genre == "F", ...)`).
- Il est possible d’emboîter plusieurs `ifelse()`, mais cela devient vite illisible → utiliser `case_when()` pour plusieurs conditions.

Recodages multiples — `case_when()`

La fonction `case_when()` est une version lisible de plusieurs `ifelse` en cascade et permet de recoder ou de créer une variable selon plusieurs conditions.

Principe

```

case_when(
  condition1 ~ valeur1,
  condition2 ~ valeur2,
  .default    = valeur_par_defaut # valeur utilisée si aucune condition n'est vraie
)

```

- Dans `case_when()`, les conditions sont testées une par une, de haut en bas.
- La **première condition vraie** détermine la valeur renvoyée.
- L'argument `.default` = permet d'indiquer une valeur à utiliser si aucune condition n'est satisfaite (sinon `.default = NULL`).
- Sans `.default`, toutes les valeurs qui ne correspondent à aucune condition deviennent NA.
- L'ordre des conditions est essentiel : toujours aller du plus **spécifique → au plus général**.

Reencoder une variable — `case_when()`

Reencoder les âges en classes

```

d |>
  mutate(age_cat = case_when(
    age < 18 ~ "<18",
    age >= 18 & age < 30 ~ "18-29",
    age >= 30 ~ "30+",
    .default = NA # NA renvoyé si aucune condition n'est vraie
  ))

```

```

# Variante : gestion explicite des valeurs manquantes avec is.na()
d |>
  mutate(age_cat = case_when(
    is.na(age) ~ NA, # attribue NA si l'âge est manquant
    age < 18 ~ "<18",
    age >= 18 & age < 30 ~ "18-29",
    .default = "30+" # toutes les autres situations (30 ans et +)
  ))

```

```

# A tibble: 4 x 13
  id_etud genre   age_filiere      abs_just abs_non_just revenu  age2 majeur age_plus_1  a
  <fct>   <fct> <dbl> <fct>           <dbl>       <dbl> <dbl> <dbl> <dbl> <lgl>   <dbl>
1 E001     F        17 Soins infirmiers      2          0    6200    289 FALSE      18

```

| | | | | | | | | | | |
|----|------|---|----|------------------|---|---|------|-----|------|----|
| 2 | E002 | H | 20 | Physiothérapie | 4 | 1 | NA | 400 | TRUE | 21 |
| 29 | | | | | | | | | | |
| 3 | E003 | F | 23 | Soins infirmiers | 1 | 2 | NA | 529 | TRUE | 24 |
| 29 | | | | | | | | | | |
| 4 | E004 | H | 19 | Ergothérapie | 3 | 0 | 4800 | 361 | TRUE | 20 |
| 29 | | | | | | | | | | |

- `is.na(x)` teste si une valeur est manquante.
- Elle renvoie TRUE si x est NA, et FALSE sinon.
- Très utile pour recoder explicitement les valeurs manquantes dans `case_when()`.

Recoder avec plusieurs variables — `case_when()`

Recoder selon l'âge et le genre

```
d |>
  mutate(age_genre = case_when(
    age >= 18 & genre == "H" ~ "Homme majeur",
    age < 18 & genre == "H" ~ "Homme mineur",
    age >= 18 & genre == "F" ~ "Femme majeure",
    age < 18 & genre == "F" ~ "Femme mineure",
    .default = NA    # NA renvoyé si aucune condition n'est vraie
  ))
```

| # | A tibble: 4 x 13 | id_etud | genre | age filiere | abs_just | abs_non_just | revenu | age2 | majeur | age_plus_1 | ... |
|---|------------------|---------|-------|------------------|----------|--------------|--------|-------|--------|------------|-----|
| | | <fct> | <fct> | <dbl> | <dbl> | <dbl> | <dbl> | <dbl> | <lgl> | <dbl> | |
| 1 | E001 | F | 17 | Soins infirmiers | 2 | 0 | 6200 | 289 | FALSE | 18 | |
| 2 | E002 | H | 20 | Physiothérapie | 4 | 1 | NA | 400 | TRUE | 21 | |
| 3 | E003 | F | 23 | Soins infirmiers | 1 | 2 | NA | 529 | TRUE | 24 | |
| 4 | E004 | H | 19 | Ergothérapie | 3 | 0 | 4800 | 361 | TRUE | 20 | |

- `case_when()` permet de combiner plusieurs variables dans les conditions (ex. âge et genre).

Interfaces graphiques de recodage

Le package `questionr` propose des interfaces graphiques (*Addins*) dans RStudio qui permettent de recoder les variables sans écrire de code.

- Chaque *Addin* génère automatiquement le code R correspondant que vous pouvez ensuite exécuter dans votre script.

Dans RStudio : **Addins** → **QUESTIONR** →

- **Levels recoding** : recoder et regrouper des modalités d'une variable catégorielle, changer la classe d'une variable
- **Levels ordering** : réordonner les niveaux d'un facteur
- **Numeric range dividing** : découper une variable numérique en classes

Les Addins interactifs du package questionr

| <i>Addin</i> (RStudio) | Fonction principale | Fonctions R équivalentes |
|-----------------------------------|---|---|
| Levels recoding | Regrouper / renommer les modalités d'un facteur ou d'un caractère | <code>fct_recode(), case_when()</code> |
| Levels ordering | Réordonner manuellement les niveaux d'un facteur | <code>fct_relevel(), factor(..., levels = ...)</code> |
| Numeric range dividing | Découper une variable numérique en classes (catégories) | <code>cut(), case_when()</code> |

- Chaque *Addin* génère automatiquement le code R reproduisant exactement la transformation choisie.
 - Vous devez ensuite exécuter ce code pour appliquer le recodage.

Ressources

- Site du tidyverse
- Introduction à R et au tidyverse